

SID Primavera 2026

Práctica 2 (Laboratorio)

Abril/Mayo 2026

1. Introducción

Durante las sesiones de laboratorio sobre aprendizaje por refuerzo, hemos introducido los conceptos básicos para abordar entornos con un MDP accesible y espacios discretos de observaciones y acciones. En esta práctica daréis un paso más allá y profundizaréis en el mismo entorno FrozenLake-v1¹, pero en modo “difícil” (diferentes niveles de estocasticidad y tamaño de mapa), explorando la escalabilidad y eficiencia de los diferentes métodos de resolución vistos en clase: Iteración de valor, Estimación directa (*model-based*), Q-Learning y REINFORCE.

2. Objetivo de la práctica

En esta práctica se os pide que diseñéis y ejecutéis experimentos para realizar un estudio del rendimiento en el entorno FrozenLake-v1, operando estrictamente en el modo estocástico (`is_slippery=True`). El foco principal del estudio será analizar cómo se comportan los agentes al someterlos a **diferentes tamaños de mapa** (por ejemplo, mapas de 4x4, 8x8 o superiores incluidos en `gymnasium` o generados por vosotros), **distintas probabilidades de éxito en la acción escogida por el agente**, y cómo escala el **rendimiento del agente** (porcentaje de episodios en los que alcanza la meta) en función de la complejidad del entorno, del método y de la parametrización elegida. Es importante que leáis con atención la documentación del entorno en la página oficial, en especial sobre el efecto de los parámetros `map_name`, `desc` y `success_rate`.

Los algoritmos a evaluar son los siguientes:

- Iteración de valor
- Estimación directa
- Q-Learning

¹https://gymnasium.farama.org/environments/toy_text/frozen_lake/

Se dará una puntuación extra a los grupos que también añadan un método de gradiente de política al estudio, como por ejemplo REINFORCE.

Los parámetros e hiperparámetros que debéis tener en cuenta para realizar el análisis deben incluir (pero no limitarse a):

- El tamaño del entorno: cuadrículas de 4x4, 8x8 o superiores (parámetros `map_name` y `desc` del entorno).
- La probabilidad de transición (parámetro `success_rate` del entorno), que dicta la probabilidad de que la acción elegida se ejecute en la dirección deseada en lugar de resbalar perpendicularmente.
- El número de episodios a entrenar.
- El factor de descuento (γ).
- La señal de recompensa²
- El coeficiente de exploración (ϵ) y su descuento (en Q-Learning).
- La tasa de aprendizaje (α) y su descuento (en Q-Learning).

Para evaluar la calidad de los entrenamientos y construir vuestro análisis, deberéis tener en cuenta los siguientes elementos (podéis añadir o modificar métricas si lo justificáis):

- Porcentaje de episodios exitosos en evaluación tras el entrenamiento.
- Evolución de la tasa de episodios exitosos durante el entrenamiento.
- Tiempo de entrenamiento por episodio y tiempo total.
- Tiempo de convergencia de la política óptima respecto al tamaño del mapa y al grado de estocasticidad (`success_rate`).
- Optimalidad de la política resultante en entornos estocásticos.

Para la práctica debéis redactar un documento que muestre las ventajas y los inconvenientes de cada método a medida que el entorno crece en complejidad, y que permita entender el efecto de los diferentes parámetros para maximizar el rendimiento final del agente entrenado.

Podéis utilizar como base el código de los notebooks de la sesión de laboratorio. También podéis modificar, optimizar o reimplementar los algoritmos siempre y cuando documentéis el proceso de diseño e implementación en la entrega.

²Podéis probar alternativas a la señal de recompensa por defecto (por ejemplo, penalizar los agujeros o el tiempo) pero, si lo hacéis, tenéis que comparar vuestras propuestas con la versión por defecto.

3. Plazos y evaluación

La entrega tiene que incluir el código de los algoritmos, así como también el código para lanzar los experimentos y no ha de incluir notebooks³. Las únicas dependencias que podéis utilizar son las mismas que ya se utilizan en los notebooks.

La fecha de entrega será el día **11 de mayo (11/05/2026)**, y consistirá en:

- El código de experimentación y los algoritmos.
- Una documentación en .pdf incluyendo:
 - Las decisiones de diseño de los experimentos, incluyendo hipótesis y una justificación de parámetros a probar y con qué rangos.
 - Un resumen de los resultados empíricos.
 - Análisis comparativo de los algoritmos y sus parametrizaciones, contextualizando cada resultado con respecto a las propiedades de los algoritmos tal como se vieron en las sesiones de teoría.
- Un fichero README con las instrucciones para parametrizar y ejecutar los experimentos.

La nota base de la práctica se evaluará según la rúbrica descrita en la Figura 1. Esta nota tendrá un valor máximo de 10. Aparte de esta nota base, existe la posibilidad de sumar puntos extra que permitirían tener una nota mayor de 10:

- 2 puntos extra a los grupos que añadan, aparte de los tres algoritmos propuestos, uno de gradiente de política (e.g. REINFORCE).

La nota de esta práctica contará un tercio de la nota global de laboratorio. Si la nota es superior al 10, para hacer media no se reducirá a 10 sino que se mantendrá superior.

³Podéis utilizar los notebooks para desarrollar algoritmos o probar experimentos, pero no para la versión final del código que entreguéis.

Criterio	Peso	Expectativa
Ejecución	40 %	El código no depende de notebooks y funciona correctamente a partir de las instrucciones del README, permitiendo fácilmente parametrizar nuevos experimentos, modificar la estocasticidad (<code>success_rate</code>) y escalar el tamaño del mapa.
Implementación	20 %	Los algoritmos que se utilizan son consistentes con su funcionamiento teórico (parámetros γ , ϵ , α y sus respectivos decay). Se proponen maneras de lidiar con la explosión del espacio de estados en mapas más grandes.
Diseño de experimentos	20 %	Los experimentos están planteados a partir de hipótesis claras y justificadas sobre cómo el aumento del tamaño del mapa y los cambios en la probabilidad de transición (<code>success_rate</code>) afectan a la convergencia y al porcentaje de episodios exitosos.
Análisis de resultados	20 %	El resultado se analiza de manera contextualizada con respecto a las hipótesis. Se incluye una discusión crítica sobre la escalabilidad (tiempo de cómputo vs. porcentaje de éxito) y se concluye con recomendaciones para entrenar agentes en entornos que crecen en complejidad.

Figura 1: Rúbrica de evaluación de la práctica